



THUYẾT MINH

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN 2024

A. THÔNG TIN CHUNG

A1. Tên đề tài

- Tên tiếng Việt (IN HOA): **PHÂN LOẠI VÀ NHẬN DIỆN MỨC ĐỘ CẢM XÚC TỪ DỮ LIỆU VĂN BẢN DỰA TRÊN MÔ HÌNH NGÔN NGỮ LỚN**
- Tên tiếng Anh (IN HOA): **EMOTION CLASSIFICATION AND INTENSITY DETECTION FROM TEXT DATA USING LARGE LANGUAGE MODEL**

A2. Thời gian thực hiện

..06.. tháng (kể từ khi được duyệt).

A3. Tổng kinh phí

Tổng kinh phí: ..6.. triệu đồng, gồm:

- Kinh phí từ Trường Đại học Công nghệ Thông tin: ..6.. triệu đồng

A4. Chủ nhiệm

Họ và tên: Lưu Gia Huy

Ngày, tháng, năm sinh: 08/05/2005

Giới tính (Nam/Nữ): Nam

Số CCCD: 083205004804

; Ngày cấp: 15/11/2021

; Nơi cấp: Cục cảnh sát

quản lý hành chính về trật tự xã hội

Mã số sinh viên: 23520618

Số điện thoại liên lạc: 0909773079

Khoa: Khoa học Máy tính

Số tài khoản: 36016847

Ngân hàng: ACB

A5. Thành viên đề tài (kể cả CNĐT)

TT	Họ tên	MSSV	Khoa
1	Nguyễn Minh Hoàng	23520530	Khoa học Máy tính
2	Lưu Gia Huy	23520618	Khoa học Máy tính

B. MÔ TẢ NGHIÊN CỨU

B1. Giới thiệu về đề tài

B1.1. Tổng quan về đề tài

Trong thời đại số hóa, dữ liệu văn bản ngày càng trở thành nguồn thông tin phong phú và đa dạng, với hàng triệu bài đăng, bình luận, và tin nhắn được tạo ra hàng ngày trên các nền tảng trực tuyến như mạng xã hội, diễn đàn, và các sàn thương mại điện tử. Những dữ liệu này không chỉ phản ánh nội dung thông tin mà còn ẩn chứa các sắc thái cảm xúc của người dùng, từ sự hài lòng, phấn nộ, cho đến sự lo âu hoặc kỳ vọng. Việc hiểu và phân tích cảm xúc từ dữ liệu văn bản trở thành một nhu cầu không thể thiếu, đặc biệt là trong các lĩnh vực như chăm sóc khách hàng, phân tích dư luận xã hội, giáo dục và sức khỏe tâm thần.

Cảm xúc, một khía cạnh vừa quen thuộc nhưng cũng đầy bí ẩn, là một phần không thể thiếu trong giao tiếp hàng ngày của con người. Chúng ta thường xuyên thể hiện và quản lý cảm xúc qua lời nói, nhưng cảm xúc thì lại rất phức tạp, đa chiều và đôi khi rất khó để diễn đạt một cách chính xác và trọn vẹn [1, 2]. Nghiên cứu về nhận diện cảm xúc (emotion recognition) tập trung vào việc hiểu và phân loại cảm xúc dựa trên ngôn ngữ. Ngôn ngữ đóng vai trò quan trọng trong việc truyền tải cảm xúc thông qua các cách thức tinh tế và đa dạng, tuy nhiên cách mọi người cảm nhận và thể hiện có thể rất khác nhau, ngay cả trong cùng một nền văn hóa hoặc một tập thể xã hội. Bài toán nhận diện cảm xúc là một tập hợp bao gồm các tác vụ phức tạp bên trong nó như xác định cảm xúc của người nói, phát hiện cảm xúc mà một đoạn văn bản truyền tải hay cảm xúc được khơi gợi lên trong người đọc khi đọc một đoạn văn bản [3].

Một thách thức lớn trong nghiên cứu cảm xúc đó là không thể xác định chính xác cảm xúc thực sự của một người khi chỉ dựa vào lời nói của họ hay những từ ngữ được viết ra. Lý giải cho việc này có thể là do bối cảnh của nền văn hóa, đặc điểm tính cách của mỗi cá nhân và sự hạn chế của giao tiếp dựa trên văn bản [4]. Điều này làm nổi bật tầm quan trọng của khái niệm **cảm xúc nhận thức được** (perceived emotions), tức là cảm xúc mà hầu hết mọi người sẽ nghĩ rằng một người nào đó có thể đang cảm nhận dựa trên lời nói hoặc văn bản. Đây cũng là chủ đề chính mà chúng tôi sẽ tập trung nghiên cứu trong đề tài này.

Trong nghiên cứu này, chúng tôi quyết định sẽ giải quyết bài toán nhận diện cảm xúc dựa trên văn bản trong Task số 11 của cuộc thi SemEval Shared Tasks 2025 ¹. Nội dung này chia thành nhiều bài toán nghiên cứu nhỏ, bao gồm:


- Bài toán 1 - Phát hiện cảm xúc đa nhãn (*Multi-label Emotion Detection*): Nhận diện đồng thời nhiều cảm xúc từ một đoạn văn bản, vốn đòi hỏi các mô hình phải hiểu sâu sắc mối quan hệ giữa các nhãn cảm xúc.
- Bài toán 2 - Nhận diện cường độ cảm xúc (*Emotion Intensity*): Xác định mức độ mạnh yếu của cảm xúc thông qua việc đo lường cường độ cảm xúc mà văn bản thể hiện.
- Bài toán 3 - Nhận diện cảm xúc đa ngôn ngữ (*Cross-lingual Emotion Detection*): Chuyển giao khả năng nhận diện cảm xúc giữa các ngôn ngữ, dự đoán nhãn cho một loại ngôn

¹SemEval-2025: The 19th International Workshop on Semantic Evaluation

ngữ khác.

Một số công trình nghiên cứu về phân tích phương pháp cho bài toán nhận diện cảm xúc đã được một số nhóm nghiên cứu thực hiện và đạt hiệu quả cao trong các bài toán 1, 2 và 3 như sau:


- Nghiên cứu của Yu và cộng sự [5] đã đề xuất một phương pháp cải thiện hiệu suất trên bài toán số 1 bằng một mô hình transfer learning mới là Dual Attention Transfer Network (DATN) 1 và sự kết hợp với Sentiment Classification. DATN chia việc học các vector biểu diễn câu (sentence representation) thành hai không gian đặc trưng: không gian cảm xúc tổng quát (sentiment space) và không gian cảm xúc cụ thể (emotion-specific space), sau đó sử dụng cơ chế chú ý kép (dual attention) để tập trung vào các từ quan trọng trong mỗi không gian, và chuyển giao thông tin học được từ các đặc trưng cảm xúc chung (general sentiment features) sang các đặc trưng cảm xúc cụ thể. Đối với bài toán số 1, DATN có tiềm năng vượt trội trong việc nắm bắt các mối quan hệ phức tạp giữa các nhãn cảm xúc thông qua cơ chế attention. Tuy nhiên, trong các bài toán số 2 và 3, mô hình này có thể cần bổ sung thêm khả năng xử lý dữ liệu ngôn ngữ đa dạng.



Hình 1: Dual Attention Transfer Network


- Nghiên cứu của Alharbi và cộng sự [6] đã đề xuất phương pháp kết hợp các biểu diễn tĩnh (static embeddings) và biểu diễn ngữ cảnh hóa (contextualized embeddings) để xác định cường độ cảm xúc và độ mạnh cảm xúc trong các bài đăng Twitter tiếng Ả Rập 2. Họ sử dụng mô hình tích hợp hai dạng embeddings (ACWE và MARBERT) thông qua mạng nơ-ron tích chập (CNN) và các lớp dense layer nhằm tăng hiệu suất đáng kể trong

các tác vụ liên quan đến cảm xúc trong tiếng Ả Rập, dùng để phân loại cảm xúc và dự đoán cường độ. Nghiên cứu này là sự kết hợp của 2 bài toán 1 và 2, đạt hiệu suất cao và vượt trội trên các bài toán ngôn ngữ chuyên biệt, cụ thể ở đây là tiếng Ả Rập. Tuy nhiên cũng như đề tài nghiên cứu trên thì cũng cần phải bổ sung thêm khả năng xử lý dữ liệu đa ngôn ngữ khi mở rộng sang bài toán số 3.




Hình 2: Các tweets đầu vào được xử lý bằng WE, CE và các thành phần liên quan + pre-trained model MARBERT, sau đó nhờ vào dense layer để học thêm các mối quan hệ phức tạp hơn

- Nghiên cứu của Kadiyala và cộng sự [7] sử dụng các mô hình ngôn ngữ lớn (LLMs), bao gồm XLM-R (mô hình encoder) và mT5 (mô hình encoder-decoder) cộng với Orca 2 - một LLM với chiến lược fine-tuning sử dụng kỹ thuật LoRA (Low-Rank Adaptation) giúp giảm yêu cầu tài nguyên khi tinh chỉnh 3. Mô hình được huấn luyện trên dữ liệu là tiếng Anh gốc và sau đó kết hợp với dữ liệu được dịch tự động sang các ngôn ngữ khác (back-translation). Nhờ tích hợp nhiều mô hình và kết hợp dữ liệu dịch tự động đã cải thiện hiệu suất và cho ra kết quả vượt trội đối với bài toán số 3 nhờ vào khả năng xử lý đa ngôn ngữ, đặc biệt trong điều kiện chỉ có dữ liệu gốc là tiếng Anh. Đối với bài toán số 1 và 2, mô hình cũng có tiềm năng trong việc nắm bắt được các mối quan hệ phức tạp giữa các nhãn cảm xúc nhờ vào sự tích hợp giữa các mô hình.



Hình 3: System Overview : Ensembles of LLMs

- Nghiên cứu của Zhang và cộng sự [8] tập trung vào việc cải thiện hiệu suất trên bài toán số 3 thông qua 2 phương pháp chính: một là tăng cường dữ liệu (data augmentation) bằng cách sử dụng các kỹ thuật dịch ngược (back-translation) và thay thế từ đồng nghĩa (synonym replacement) để mở rộng tập dữ liệu, giúp cải thiện tính đa dạng ngôn ngữ; hai là ánh xạ nhãn-token (token-label mapping) liên kết các subword với nhãn cảm xúc, từ đó xác định chính xác các từ kích hoạt cảm xúc (emotion trigger identification) 4. Họ sử dụng các mô hình tiền huấn luyện, tối ưu hóa bằng các kỹ thuật nêu trên để giúp mô hình học được nhiều đặc trưng hơn, đạt hiệu quả rất tốt đối với 2 dạng bài toán 1 và 2 khi xử lý dữ liệu. Đối với dạng bài toán số 3, mô hình có tiềm năng và sẽ hiệu quả tốt khi tích hợp với các mô hình ngôn ngữ lớn.



Hình 4: Data Augmentation & Token-Label Mapping

Nhìn chung, mỗi nghiên cứu trên đều có những ưu điểm nhất định tùy thuộc vào đặc thù bài toán và ngôn ngữ xử lý. Tuy nhiên, khi xem xét sự cân bằng giữa hiệu quả, tính linh hoạt, và khả năng mở rộng, chúng tôi quyết định sẽ lựa chọn các mô hình dựa trên BERT và các biến thể của BERT đóng vai trò trung tâm trong đề tài nghiên cứu này. BERT, với kiến trúc attention mạnh mẽ và khả năng huấn luyện trên lượng lớn dữ liệu, không chỉ thể hiện hiệu suất cao trong việc học các mối quan hệ phức tạp giữa các nhãn cảm xúc mà còn thích nghi tốt với các bài toán đa ngôn ngữ nhờ các biến thể như XLM-R, mT5 hay mBERT.

B1.2. Các thách thức

- Một thách thức lớn trong quá trình nghiên cứu nằm ở vấn đề dữ liệu không đồng nhất giữa các ngôn ngữ và sự khác biệt văn hóa trong cách biểu đạt cảm xúc, gây khó khăn cho việc áp dụng mô hình vào bài toán dự đoán cảm xúc đa ngôn ngữ.
- Ngoài ra, chi phí tính toán cao khi huấn luyện và tối ưu các mô hình lớn như BERT hoặc XLM-R cũng là một trở ngại trong quá trình nghiên cứu. Điều này đòi hỏi chúng tôi phải có các phương pháp xử lý sao cho phù hợp và hiệu quả để cải thiện hiệu suất của mô hình.

B2. Mục tiêu, nội dung, kế hoạch nghiên cứu

B2.1. Mục tiêu

Mục tiêu:

- **Mục tiêu 1:** Cài đặt và đánh giá các phương pháp tiếp cận dựa trên mô hình ngôn ngữ lớn, pre-trained models
 - Các mô hình được dùng để thử nghiệm bao gồm các mô hình đã huấn luyện như BERT [9], RoBERTa [10], DeBERTa [11], mBERT [12], mDeBERTa, T5 [13] để gán nhãn cảm xúc.
 - Tiêu chí đánh giá:
 - * Độ chính xác (accuracy), F1-Score, Recall, Precision, ROC-AUC.
 - * Khả năng tổng quát hóa và hiệu suất trên các ngôn ngữ khác nhau. VD: kiểm tra trên tập dữ liệu chưa từng thấy (unseen test set) hoặc sử dụng cross-lingual evaluation để đánh giá khả năng tổng quát hóa giữa các ngôn ngữ.
- **Mục tiêu 2:** Nghiên cứu các phương pháp tinh chỉnh và cải thiện hiệu suất trong các mô hình ngôn ngữ lớn
 - Tinh chỉnh mô hình theo các phương pháp:
 - * Standard Fine-tuning: Huấn luyện toàn bộ tham số trên tập dữ liệu cụ thể.
 - * Fine-tuning với Freezing Layers: Đóng băng một số lớp để giảm chi phí tính toán.
 - * Adapter Layers: Chỉ thêm các lớp nhỏ vào mô hình để tinh chỉnh nhẹ.
 - * Prompt-based Fine-tuning: Tối ưu hóa dựa trên các lời nhắc thiết kế tốt.
 - Nghiên cứu mở rộng dữ liệu (Data Augmentation):
 - * Kỹ thuật tăng cường văn bản như dịch ngược (back-translation), thay từ đồng nghĩa thêm nhiễu Gaussian.
 - * Đánh giá khả năng giảm overfitting và cải thiện hiệu suất mô hình.
- **Mục tiêu 3:** So sánh, đánh giá và đề xuất hướng nghiên cứu:
 - So sánh các phương pháp tinh chỉnh: Đánh giá ưu và nhược điểm của từng cách tiếp cận.
 - Đề xuất hướng cải tiến:
 - * Xác định các điểm yếu trong mô hình hiện tại.
 - * Gợi ý nghiên cứu sâu hơn như các kỹ thuật meta-learning, mô hình đa ngôn ngữ nâng cao, hoặc tích hợp cảm xúc theo thời gian thực.

Đối tượng nghiên cứu:

- Bộ dữ liệu sử dụng cho nghiên cứu: SemEval-2025 Task 11 - Bridging the Gap in Text-Based Emotion Detection.
 - Đặc điểm chính:
 - * Đa ngôn ngữ: English, German, Russian.
 - * Gán nhãn cảm xúc: Anger, Disgust, Fear, Joy, Sadness, Surprise.
 - * Dữ liệu: 0 (không có) hoặc 1 (có) cho mỗi nhãn cảm xúc (bài toán 1) hoặc là các số nguyên (từ 0 đến 3) biểu diễn cường độ của từng nhãn cảm xúc.
 - Tiền xử lý dữ liệu:
 - * Xử lý mất cân bằng nhãn bằng các kỹ thuật như oversampling hoặc SMOTE để cải thiện hiệu suất các nhãn ít xuất hiện.

- * Xử lý dữ liệu nhiễu: loại bỏ các dữ liệu nhiễu, chuẩn hóa văn bản và chuẩn bị tập dữ liệu sạch trước khi huấn luyện
- * Phân chia tập kiểm thử: phân chia thành tập dữ liệu huấn luyện (train), kiểm thử (test) và kiểm định (validation).
- Thách thức:
 - * Mất cân bằng nhãn (Imbalanced Labels): Một số cảm xúc có thể xuất hiện ít hơn, gây khó khăn cho huấn luyện.
 - * Đa ngôn ngữ: Hiệu suất giữa các ngôn ngữ có thể không đồng nhất.
 - * Dữ liệu nhiễu: Sự chênh lệch về độ dài giữa các đoạn văn bản hoặc xuất hiện các yếu tố không mong muốn.
- Mô tả bài toán:
 - Đầu vào: đoạn văn bản bất kỳ
 - Đầu ra:
 - * Bài toán 1: dạng nhị phân 0 hoặc 1 cho từng nhãn cảm xúc ứng với đoạn văn bản đó có thể hiện loại cảm xúc đó hay không.
 - * Bài toán 2: các số nguyên từ 0 đến 3 cho từng nhãn cảm xúc ứng với đoạn văn bản đó thể hiện loại cảm xúc đó ở một mức độ như thế nào.
- Các mô hình dùng trong nghiên cứu:
 - Các mô hình BERT, RoBERTa và DeBERTa sẽ được tinh chỉnh để xử lý bài toán.
 - Các mô hình mBERT và mDeBERTa sẽ giúp đánh giá khả năng phân loại cảm xúc trong môi trường đa ngôn ngữ.
 - Mô hình T5 sẽ được sử dụng để kiểm tra khả năng sinh nhãn cảm xúc từ các văn bản đầu vào với khả năng tổng quát hóa khi áp dụng cho nhiều loại ngôn ngữ.

Phạm vi nghiên cứu:

- Đánh giá hiệu suất: So sánh các mô hình dựa trên các chỉ số như độ chính xác (accuracy), F1-score, precision, recall và ROC-AUC. Phân tích hiệu suất trên từng nhãn cảm xúc (Label-wise Performance) để xác định nhãn nào là dễ hoặc khó phân loại nhất. Ngoài ra, áp dụng weighted F1-score để giảm thiểu ảnh hưởng của việc mất cân bằng nhãn trong dữ liệu.
- Ngữ cảnh và ngôn ngữ: Phân tích hiệu suất trên từng ngôn ngữ (English, German, Russian) và đánh giá khả năng tổng quát hóa của các mô hình trong môi trường đa ngôn ngữ.
- Tinh chỉnh và cải thiện: Khảo sát các phương pháp tinh chỉnh (fine-tuning) như truyền thống, freezing layers, adapter layers, cùng các phương pháp mở rộng dữ liệu (data augmentation).
- Môi trường thực nghiệm: Hugging Face Transformers.

B2.2. Nội dung và phương pháp nghiên cứu

Nội dung 1: Tìm hiểu và phân tích các nghiên cứu trước đó có liên quan đến đề tài.

- **Mục tiêu:** Khảo sát các nghiên cứu trước đây về chủ đề nghiên cứu hoặc bài toán có liên quan đến xác định các thông tin cần thiết. Các thông tin bao gồm các phương pháp giải quyết, ưu điểm, nhược điểm của từng phương pháp trên bài toán nghiên cứu đó.
- **Phương pháp thực hiện:** Tra cứu trên các dữ liệu khoa học như Google Scholar bằng cách thiết kế ra các từ khóa liên quan đến các mô hình ngôn ngữ lớn (LLMs), mô hình BERT hoặc bài toán về Emotion Detection.
- **Kết quả dự kiến:** Báo cáo chi tiết về các khảo sát nghiên cứu trước đó liên quan đến đề tài.

Nội dung 2: Nghiên cứu các phương pháp tiền xử lý dữ liệu.

- **Mục tiêu:** Làm sạch dữ liệu, tăng chất lượng dữ liệu, xử lý mất cân bằng nhãn và tăng cường dữ liệu.
- **Phương pháp thực hiện:**
 - Làm sạch dữ liệu bằng cách loại bỏ ký tự không mong muốn, xử lý lỗi chính tả, loại bỏ các stop word.
 - Xử lý dữ liệu nhiễu: Loại bỏ hoặc chỉnh sửa các văn bản không hoàn chỉnh, loại bỏ các bản ghi bị trùng lặp.
 - Xử lý mất cân bằng nhãn: Tăng số lượng mẫu cho các nhãn ít phổ biến (sử dụng SMOTE, Random Oversampling).
 - Tăng cường dữ liệu: Back-translation dịch văn bản sang ngôn ngữ khác rồi dịch ngược về ngôn ngữ gốc để tạo ra các mẫu mới, Synonym Replacement thay từ bằng từ đồng nghĩa để tạo ra đa dạng dữ liệu, Random Noise Addition thêm nhiễu nhỏ vào dữ liệu để kiểm tra tính ổn định của mô hình.
- **Kết quả dự kiến:** Một bộ dữ liệu sạch, đồng nhất và cân bằng phối giữa các nhãn. Sau bước tiền xử lý, dữ liệu đạt trạng thái tối ưu sẵn sàng đưa vào mô hình để thực hiện huấn luyện.

Nội dung 3: Cài đặt các mô hình, thực hiện các phương pháp tinh chỉnh trên các mô hình.

- **Mục tiêu:** Cài đặt và huấn luyện các mô hình ngôn ngữ lớn (LLMs) và các biến thể của chúng như BERT, RoBERTa, DeBERTa, mBERT, mBERTa và T5. Áp dụng các phương pháp tinh chỉnh (fine-tuning) khác nhau nhằm cải thiện hiệu suất của các mô hình.
- **Phương pháp thực hiện:**
 - Cài đặt các mô hình cơ sở: Tải các mô hình đã được huấn luyện trước từ thư viện Hugging Face Transformers (BERT, RoBERTa, DeBERTa, T5). Áp dụng các cấu hình cơ bản như số lượng lớp, kích thước batch và tỉ lệ học (learning rate).
 - Áp dụng các phương pháp tinh chỉnh: Standard Fine-tuning, Freezing Layers Fine-tuning, Adapter Layers Fine-tuning, Prompt-based Fine-tuning.
 - Huấn luyện và đánh giá mô hình: Huấn luyện dựa trên tập dữ liệu đã tiền xử lý, sử dụng các kỹ thuật như Early Stopping để tránh overfitting. Sử dụng tập kiểm định (validation set) để điều chỉnh siêu tham số. Đánh giá hiệu suất trên tập kiểm thử (test set).
 - Kết hợp với kỹ thuật tăng cường dữ liệu: Sử dụng dữ liệu đã tăng cường để tăng tính đa dạng và khả năng tổng quát hóa của mô hình.
- **Kết quả dự kiến:** Hiệu suất của mô hình gồm bảng so sánh chi tiết các chỉ số đánh giá như Accuracy, Precision, Recall, F1-Score, ROC-AUC giữa các mô hình và phương pháp tinh chỉnh, đánh giá chi tiết hiệu suất trên từng nhãn cảm xúc và hiệu suất tổng thể trên các ngôn ngữ khác nhau (English, German, Russian).

Nội dung 4: Phân tích và đánh giá hiệu suất mô hình.

- **Mục tiêu:**
 - So sánh hiệu suất các mô hình đã cài đặt trên tập kiểm thử (test set) và tập kiểm định (validation set).
 - Xác định những yếu tố ảnh hưởng đến độ chính xác, khả năng tổng quát hóa, và hiệu quả đa ngôn ngữ.

- **Phương pháp thực hiện:**

- Sử dụng các chỉ số đánh giá: Accuracy, Precision, Recall, F1-score, ROC-AUC và weighted F1-score.
- So sánh hiệu suất theo từng nhãn cảm xúc (label-wise performance) để xác định nhãn nào khó phân loại nhất.
- Phân tích ảnh hưởng của dữ liệu nhiều hoặc mất cân bằng nhãn đến mô hình.
- Phân tích chi tiết các trường hợp mô hình sai (misclassified), xác định nguyên nhân lỗi.
- Đánh giá ảnh hưởng của các siêu tham số (learning rate, batch size...) lên hiệu suất mô hình.
- Đánh giá tác động của từng phương pháp tinh chỉnh (standard fine-tuning, freezing layers, adapter layers, ...)

- **Kết quả dự kiến:**

- Báo cáo chi tiết về hiệu suất từng mô hình.
- Phát hiện các nhãn hoặc ngôn ngữ có hiệu suất thấp và lý do cụ thể.

Nội dung 5: Đề xuất cải tiến mô hình và phương pháp trong tương lai.

- **Mục tiêu:**

- Đưa ra các gợi ý cải thiện mô hình dựa trên kết quả đánh giá.
- Hướng dẫn nghiên cứu tiếp theo cho bài toán này.

- **Phương pháp thực hiện:**

- Khảo sát các kỹ thuật tiên tiến chưa được áp dụng như Meta-learning, Few-shot Learning, Multi-task Learning.
- Đề xuất cải thiện dữ liệu: Mở rộng tập dữ liệu bằng các kỹ thuật tổng hợp dữ liệu tự động, tăng cường ngữ cảnh trong dữ liệu (contextual augmentation).
- Fine-tuning dựa trên các kiến trúc mới như LoRA (Low-Rank Adaptation) [14] để cải thiện tính linh hoạt và giảm chi phí tính toán.
- Khám phá khả năng kết hợp mô hình với công nghệ đa phương thức (multi-modal learning), ví dụ tích hợp phân tích cảm xúc dựa trên văn bản và hình ảnh.

- **Kết quả dự kiến:** một danh sách các ý tưởng và hướng nghiên cứu cụ thể, khả thi cho bài toán.

Nội dung 6: Những hạn chế trong nghiên cứu.

- **Mục tiêu:** Xác định những điểm còn hạn chế trong nghiên cứu để cải thiện trong tương lai.

- **Phương pháp thực hiện:** phân tích các yếu tố như

- Dữ liệu không đủ đa dạng hoặc không cân bằng.
- Hiệu suất mô hình chưa đồng đều trên các ngôn ngữ.
- Tài nguyên tính toán hạn chế khi áp dụng mô hình lớn..

- **Kết quả dự kiến:** Báo cáo chi tiết về các hạn chế và nguyên nhân.

Nội dung 7: Kết luận.

Kỳ vọng đóng góp của nghiên cứu:

- Nghiên cứu có thể là nền tảng để phát triển các hệ thống cảm xúc thông minh hỗ trợ con người.
- Đóng góp vào việc giải quyết bài toán xử lý ngôn ngữ đa ngôn ngữ một cách hiệu quả.

B2.3. Kế hoạch nghiên cứu

Thời gian	Nội dung	Kết quả dự kiến
Tuần 1 - 4	• Tìm hiểu, phân tích các nghiên cứu đã có trước đó về bài toán. • Tìm hiểu, nghiên cứu và thực hiện tiền xử lý dữ liệu.	• Hiểu rõ về bài toán và các phương pháp từ các nghiên cứu trước đó. • Hoàn thành xử lý bộ dữ liệu, sẵn sàng huấn luyện và đánh giá.
Tuần 4 - 5	• Nghiên cứu, tìm hiểu chi tiết về các mô hình ngôn ngữ lớn và các phương pháp tinh chỉnh. • Chuẩn bị cấu hình thử nghiệm ban đầu cho các mô hình.	• Hoàn thành tài liệu chi tiết về đặc điểm các mô hình và các phương pháp tinh chỉnh trên các mô hình đó. • Xây dựng cấu hình thử nghiệm đầu tiên và các giả thuyết nghiên cứu.
Tuần 6 - 9	• Tiến hành cài đặt các mô hình và áp dụng các phương pháp tinh chỉnh. • Thực hiện huấn luyện các mô hình và tính toán kết quả.	Bảng tổng hợp chi tiết hiệu suất của các mô hình và phương pháp tinh chỉnh dựa trên các chỉ số đánh giá.
Tuần 10 - 11	• Phân tích và đánh giá các mô hình dựa trên các tập kiểm thử. • So sánh hiệu suất và khả năng tổng quát hóa của các mô hình và phương pháp tinh chỉnh.	• Viết báo cáo so sánh chi tiết hiệu suất các mô hình trên từng nhãn cảm xúc. • Xác định mô hình và phương pháp tinh chỉnh hiệu quả nhất.
Tuần 12 - 14	• Phân tích các hạn chế của mô hình và nghiên cứu các yếu tố ảnh hưởng đến kết quả. • Đề xuất giải pháp cải tiến và các hướng nghiên cứu tiếp theo.	• Báo cáo phân tích chi tiết hạn chế của mô hình và các nguyên nhân ảnh hưởng đến hiệu suất. • Đưa ra các giải pháp cải tiến khả thi và hướng nghiên cứu tiếp theo.
Tuần 14 - 16	• Tổng kết nghiên cứu và hoàn thiện báo cáo. • Xây dựng ứng dụng minh họa kết quả nghiên cứu.	• Tổng kết những kết quả đã đạt được và đánh giá điểm mạnh, điểm yếu của nghiên cứu. • Hoàn thiện báo cáo cuối cùng và phát triển một ứng dụng minh họa kết quả nghiên cứu. • Đánh giá ảnh hưởng của nghiên cứu.

B3. Kết quả dự kiến

- Tổng hợp khảo sát hiệu suất của nhiều mô hình khác nhau trên bộ dữ liệu SemEval-2025 Task 11 - Bridging the Gap in Text-Based Emotion Detection.
- Tổng hợp kết quả thử nghiệm nhiều phương pháp tinh chỉnh khác nhau trên các mô hình ngôn ngữ lớn.
- Tổng hợp các ý tưởng và phương pháp cải tiến hiệu suất mô hình.

- Xây dựng ứng dụng minh họa kết quả nghiên cứu.
- Báo cáo kết quả nghiên cứu.

B4. Tài liệu tham khảo

- [1] Janyce Wiebe, Theresa Wilson, and Claire Cardie. “Annotating Expressions of Opinions and Emotions in Language”. In: *Language Resources and Evaluation* 39 (2005), pp. 165–210.
- [2] Habibeh Naderi, Behrouz Haji Soleimani, Saif Mohammad, Svetlana Kiritchenko, and Stan Matwin. “DeepMiner at SemEval-2018 Task 1: Emotion Intensity Recognition Using Deep Representation Learning”. In: *Proceedings of the 12th International Workshop on Semantic Evaluation*. 2018, pp. 305–312.
- [3] Saif M. Mohammad. “Sentiment analysis: Automatically detecting valence, emotions, and other affectual states from text”. In: *Emotion Measurement (Second Edition)* 11 (2021), pp. 323–379.
- [4] Lieve Van Woensel and Nissy Nevil. “What if your emotions were tracked to spy on you?” In: *Scientific Foresight: What if?* (2019).
- [5] Jianfei Yu, Luís Marujo, Jing Jiang, Pradeep Karuturi, and William Brendel. “Improving Multi-label Emotion Classification via Sentiment Classification with Dual Attention Transfer Network”. In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*. 2018, pp. 1097–1102.
- [6] Abdullah I. Alharbi, Phillip Smith, and Mark Lee. “Enhancing Contextualised Language Models with Static Character and Word Embeddings for Emotional Intensity and Sentiment Strength Detection in Arabic Tweets”. In: *5th International Conference on AI in Computational Linguistics* 189 (2021), pp. 258–265.
- [7] Ram Mohan Rao Kadiyala. “Cross-lingual Emotion Detection through Large Language Models”. In: *Proceedings of the 14th Workshop on Computational Approaches to Subjectivity, Sentiment, and Social Media Analysis*. 2024, pp. 464–469.
- [8] Jinghui Zhang, Yuan Zhao, Siqin Zhang, Ruijing Zhao, and Siyu Bao. “Enhancing Cross-Lingual Emotion Detection with Data Augmentation and Token-Label Mapping”. In: *Proceedings of the 14th Workshop on Computational Approaches to Subjectivity, Sentiment, and Social Media Analysis*. 2024, pp. 528–533.
- [9] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: (2018).
- [10] Wenxiong Liao, Bi Zeng, Xiuwen Yin, and Pengfei Wei. “An improved aspect-category sentiment analysis model for text sentiment analysis based on RoBERTa”. In: *Applied Intelligence* 51 (2020), pp. 3522–3533.
- [11] Adel Assiri, Abdu Gumaei, Faisal Mehmood, Touqeer Abbas, and Sami Ullah. “DeBERTa-GRU: Sentiment Analysis for Large Language Model”. In: *Computers, Materials and Continua* 79 (2024).
- [12] Abhilash Pathak, Sudhanshu Kumar, Partha Pratim Roy, and Byung-Gyu Kim. “Aspect-Based Sentiment Analysis in Hindi Language by Ensembling Pre-Trained mBERT Models”. In: *Electronics* (2021).
- [13] Peiyu Liu and Weibin Guo. “A Sentiment Analysis Model Based on Text Generation-OpinionSpanT5”. In: *2024 IEEE 2nd International Conference on Control, Electronics and Computer Technology (ICCECT)*. 2024.
- [14] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. “LoRA: Low-Rank Adaptation of Large Language Models”. In: (2021).

Ngày 23 tháng 11 năm 2024

Giảng viên hướng dẫn

(Ký và ghi rõ họ tên)



Ths. Đặng Văn Thìn

Ngày 23 tháng 11 năm 2024

Chủ nhiệm đề tài

(Ký và ghi rõ họ tên)



Lưu Gia Huy